

Министерство цифрового развития, связи и массовых
коммуникаций Российской Федерации
Ордена Трудового Красного Знамени федеральное государственное
бюджетное образовательное учреждение
высшего образования
«Московский технический университет связи и информатики»
(МТУСИ)

ОТЧЕТ
по учебной практике

Направление подготовки
09.04.01 – «Информатика и вычислительная техника»
Направленность (профиль)
«Технологии и системы искусственного интеллекта»

Тема: «Разработка учебного прототипа системы
прогнозирования и обнаружения аномалий
во временных рядах»

Студент гр. М092501(77) Капустин М.С.
Руководитель: зав. кафедрой МКиИТ, к.т.н., доц. Городничев М.Г.

Москва 2026 г.

Содержание

Введение

1. Теоретические основы и характеристика набора данных

1.1 Краткая теория прогнозирования временных рядов

1.2 Методы обнаружения аномалий

2. Загрузка, обработка и визуальный анализ данных

2.1 Загрузка данных и первичный осмотр

2.2 Предварительная подготовка данных

2.3 Визуальный анализ временного ряда

3. Прогнозирование и обнаружение аномалий

3.1 Подготовка данных для моделирования

3.2 Базовая модель прогнозирования

3.3 Дополнительная модель прогнозирования

3.4 Сравнение моделей прогнозирования

Заключение

Список литературы

Введение

Временные ряды — это последовательности значений некоторой величины, зафиксированных через равные промежутки времени. Такие данные встречаются повсеместно: в экономике, метеорологии, медицине, при промышленном мониторинге и, в частности, в космической телеметрии. Работа с временными рядами включает в себя прогнозирование будущих значений на основе истории, а также поиск аномалий — нехарактерных отклонений, которые могут говорить о неполадках, сбоях или других важных событиях [1].

Обнаружение аномалий во временных рядах — одна из ключевых задач интеллектуального анализа данных. Аномалия, или выброс, — это точка, которая заметно отличается от ожидаемого поведения ряда. В телеметрии космических аппаратов такие отклонения могут предупреждать об отказах бортовых систем, ухудшении работы датчиков или нештатных ситуациях. Своевременное выявление подобных аномалий крайне важно для надёжности и безопасности космических миссий [3].

Цель данной учебной практики — разработать учебный прототип системы для прогнозирования и обнаружения аномалий во временных рядах, используя реальные данные из бенчмарка Numenta Anomaly Benchmark (NAB).

Для достижения цели были поставлены следующие задачи: выбор подходящего набора данных; загрузка и предварительная обработка; визуальный анализ временных рядов; построение моделей прогнозирования на основе Random Forest и ARIMA; обнаружение аномалий с помощью z-оценки и межквартильного размаха; сравнительный анализ результатов и оценка качества моделей.

В качестве предметной области выступает мониторинг телеметрических данных. Источником служит набор NAB, который содержит размеченные временные ряды из различных реальных и синтетических сценариев. Выбор этого бенчмарка обусловлен его практической значимостью для задач прогнозирования и поиска аномалий, а также наличием размеченных данных с известными аномалиями, что позволяет количественно оценить эффективность применяемых методов [5].

1. ТЕОРЕТИЧЕСКИЕ ОСНОВЫ И ХАРАКТЕРИСТИКА НАБОРА ДАННЫХ

1.1 Краткая теория прогнозирования временных рядов

Временной ряд представляет собой последовательность измерений некоторой случайной величины, упорядоченных во времени. Формально его можно описать как набор значений $x(t_1), x(t_2), \dots, x(t_n)$, где моменты времени удовлетворяют условию $t_1 < t_2 < \dots < t_n$, а $x(t_i)$ — наблюдение в момент t_i . Ключевая особенность таких данных — наличие корреляционных связей между отдельными отсчётами, что принципиально отличает их от независимых выборок и требует применения специализированных аналитических подходов [1].

В структуре временного ряда принято выделять несколько составляющих: тренд (долгосрочную направленность изменения показателя), сезонность (регулярные периодические колебания), циклическую компоненту (колебания с периодом, превышающим один год) и случайный шум (нерегулярные флуктуации, не поддающиеся систематическому описанию). Декомпозиция ряда на эти компоненты служит важным подготовительным этапом, помогающим обоснованно выбирать модели для прогнозирования. Для такого разложения часто применяют методы скользящего среднего, экспоненциальное сглаживание и регрессионный анализ [2].

Среди классических статистических подходов к прогнозированию временных рядов особое место занимают модели авторегрессии — проинтегрированного скользящего среднего (ARIMA). Модель $ARIMA(p, d, q)$ задаётся тремя параметрами: порядком авторегрессии p , степенью разности d , необходимой для достижения стационарности, и порядком скользящего среднего q . Оптимальные значения p, d, q подбирают на основе анализа автокорреляционной и частной автокорреляционной функций, а также с использованием информационных критериев Акаике и Байеса [6].

В области машинного обучения для решения задач прогнозирования временных рядов можно выделить два принципиально разных подхода: линейную регрессию и рекуррентные нейронные сети с долгой краткосрочной памятью (LSTM). Линейная регрессия — это простой и интерпретируемый метод, прогноз которого строится как линейная комбинация входных признаков; она вычислительно эффективна, но ограничена в моделировании нелинейных зависимостей. Напротив, LSTM-сети специально разработаны для работы с последовательными данными. Благодаря встроенным механизмам «ворот» они способны запоминать информацию на длительных интервалах и эффективно улавливать сложные нелинейные динамики, что делает их мощным инструментом для прогнозирования временных рядов [1].

Важным приёмом при конструировании признаков для прогнозирования является использование лаговых переменных. Лаг — это значение ряда, сдвинутое на один или несколько шагов назад (например, лаг 1 соответствует предыдущему наблюдению, лаг 2 — значению два шага ранее и т.д.).

Включение таких признаков позволяет переформулировать задачу прогнозирования как стандартную задачу обучения с учителем: целевая переменная — текущее значение, а признаки — предшествующие отсчёты ряда. Кроме того, для повышения качества моделей (как линейной регрессии, так и LSTM) часто добавляют статистические характеристики — скользящее среднее, скользящее стандартное отклонение, разности и другие производные показатели [2].

1.2 Методы обнаружения аномалий

Аномалией во временном ряду называют отдельное наблюдение или целый интервал данных, поведение которых заметно отличается от ожидаемой динамики ряда. По своему характеру такие отклонения делят на три типа: точечные (единичные выбросы), контекстные (значения, кажущиеся необычными только в определённых условиях) и коллективные (группа точек, вместе образующих аномальный паттерн). Выявление аномалий крайне востребовано в самых разных сферах — от контроля промышленного оборудования и поиска мошеннических операций до диагностики технических систем [3].

Среди статистических подходов к поиску аномалий распространены методы, опирающиеся на предположения о распределении данных. Один из них — z -оценка: для каждого наблюдения вычисляется стандартизированное отклонение от среднего по формуле $z = (x - \mu) / \sigma$, где x — значение, μ — среднее, σ — стандартное отклонение. Точки, чей модуль z -оценки превышает установленный порог, считаются аномальными. Этот способ прост в применении, но чувствителен к выбросам, так как сами аномалии влияют на расчёт среднего и стандартного отклонения [4].

Более устойчивый к выбросам статистический инструмент — метод межквартильного размаха (IQR). Здесь размах определяется как разность между третьим и первым квартилями ($Q_3 - Q_1$). Нормальным считается диапазон $[Q_1 - 1.5 \cdot IQR, Q_3 + 1.5 \cdot IQR]$. Всё, что оказывается вне этих границ, помечается как аномалия. Главное преимущество IQR перед z -оценкой — меньшая зависимость от экстремальных значений, поскольку квартили гораздо менее чувствительны к выбросам, чем среднее и дисперсия [5].

Среди методов машинного обучения особого внимания заслуживает алгоритм Isolation Forest. Его идея — случайное разбиение пространства признаков: аномальные объекты, будучи редкими и сильно отличающимися от основной массы, изолируются за меньшее число шагов, чем обычные точки. Алгоритм строит множество случайных деревьев решений, каждое из которых выбирает признак и порог разбиения случайным образом. Длина пути от корня к листу

служит мерой аномальности: чем путь короче, тем более подозрительным считается наблюдение [4].

Ещё один подход — обнаружение аномалий через ошибку прогнозирования. Он сравнивает реальные значения ряда с предсказаниями, полученными от модели прогноза. Если расхождение между фактом и прогнозом превышает заданный порог, точка объявляется аномальной. Этот метод исходит из предположения, что модель хорошо описывает нормальное поведение ряда, а большие ошибки возникают именно из-за аномальных событий. Его преимущество — способность выявлять контекстные аномалии, которые могут и не быть выбросами по абсолютному значению, но нарушают ожидаемый паттерн в данных условиях [3].

1.3 Выбор и описание набора данных

Набор данных **Numenta Anomaly Benchmark (NAB)** представляет собой бенчмарк, созданный для оценки алгоритмов обнаружения аномалий в потоковых данных реального времени. Он включает в себя более **50 размеченных файлов временных рядов**, как реальных, так и искусственных. Данные охватывают различные сценарии: метрики работы облачных сервисов (например, показатели AWS), данные с датчиков, показатели финансовых операций, а также синтетические временные ряды, моделирующие различные аномальные ситуации.

Корпус NAB спроектирован специально для исследований в области потокового обнаружения аномалий. Все временные ряды в наборе данных содержат **размеченные аномальные периоды**, причём разметка выполнена вручную экспертами по строгой и документированной процедуре. Это позволяет использовать NAB как для обучения моделей с учителем, так и для объективной валидации методов обнаружения аномалий без учителя.

Структура набора данных представляет собой совокупность отдельных файлов, каждый из которых соответствует одному временному ряду. В каждом файле строки представляют собой временные отсчёты, а столбцы — значения наблюдаемых показателей. Все аномалии имеют метки, указывающие на начало и конец аномального интервала. В рамках данной работы проводится комплексный анализ доступных временных рядов из набора NAB. Разнородная структура данных позволяет анализировать как отдельные ряды, так и исследовать взаимосвязи между различными показателями, что повышает информативность результатов и достоверность обнаружения аномалий.

Выбор набора данных NAB для выполнения учебной практики обусловлен несколькими факторами. **Во-первых**, это реальные и синтетические данные, отражающие различные аномальные ситуации из разных предметных

областей, что повышает практическую значимость исследования. **Во-вторых**, наличие размеченных аномалий, созданных по строгой методике, позволяет объективно оценить эффективность методов обнаружения. **В-третьих**, NAV является общедоступным бенчмарком, широко используемым в научных публикациях, что обеспечивает воспроизводимость результатов и возможность сравнения с другими исследованиями. **В-четвёртых**, разнообразие временных рядов в NAV позволяет провести масштабный анализ различных типов данных и оценить применимость методов к различным сценариям.

Структура набора данных включает множество временных рядов с временной привязкой, что позволяет проводить как одномерный, так и многомерный анализ для каждого из представленных сценариев.

2. ЗАГРУЗКА, ОБРАБОТКА И ВИЗУАЛЬНЫЙ АНАЛИЗ ДАННЫХ

2.1 Загрузка данных и первичный осмотр

Для загрузки и обработки данных использовалась библиотека `pandas` языка Python. Исходные данные были представлены в формате CSV и загружены с использованием функции `pandas.read_csv()`. При загрузке были указаны параметры парсинга временных меток, а столбец с датой и временем установлен в качестве индекса. Первичный осмотр данных включал вывод первых строк таблицы с помощью `head()`, получение общей информации о структуре датафрейма методом `info()` и вычисление основных статистических характеристик с помощью `describe()`.

В результате первичного осмотра было установлено, что набор данных представляет собой одномерный временной ряд, содержащий **4032 наблюдения** с частотой дискретизации **5 минут**. Данные охватывают период с 1 апреля 2014 года по 15 апреля 2014 года (14 суток). Структура данных предельно проста: один столбец `value` с вещественными числами типа `float64`. Пропуски и дубликаты отсутствуют, что подтверждает корректность исходного файла.

Анализ статистических характеристик показал, что значения ряда изменяются в диапазоне от **18.0** до **164.9** единиц, среднее значение составляет **44.5**, а стандартное отклонение — **32.4**. Квартили (25%, 50%, 75%) равны соответственно **19.99**, **21.65** и **76.44**, что указывает на асимметричное распределение с выраженными пиковыми выбросами в верхней части. Такой разброс значений характерен для реальных телеметрических или сенсорных данных и не требует дополнительной нормализации, поскольку методы обнаружения аномалий (z-оценка, межквартильный размах) могут работать с исходным масштабом.

Для визуального анализа временного ряда были построены графики, представленные на рисунках 1 и 2. Четко видна аномалия – период 11 марта. Скользящее среднее позволяет сгладить высокочастотные колебания и выделить общий тренд, который на данном интервале остаётся относительно стабильным, за исключением нескольких резких всплесков. **На рисунке 2** приведено скользящее стандартное отклонение, которое наглядно демонстрирует периоды повышенной волатильности — именно в эти моменты наиболее вероятно возникновение аномалий. Совместный анализ этих графиков даёт первичное представление о характере ряда и помогает выбрать пороговые значения для статистических методов обнаружения выбросов.

Общий объём данных (4032 точки) является достаточным для построения моделей прогнозирования (ARIMA, линейная регрессия, LSTM) и апробации методов обнаружения аномалий, так как выборка включает как длительные участки стационарного поведения, так и кратковременные аномальные всплески.



Рис. 1. Временной ряд



Рис. 2. Скользящее стандартное отклонение

3. ПРОГНОЗИРОВАНИЕ И ОБНАРУЖЕНИЕ АНОМАЛИЙ

3.1 Подготовка данных для моделирования

Подготовка данных для построения моделей прогнозирования включала создание лаговых признаков на основе исходного временного ряда. Для каждого момента времени t были сформированы признаки, представляющие собой значения ряда в предшествующие моменты: lag1 , lag2 и lag3 — соответственно значения на один, два и три шага назад. Выбор именно трёх лагов обусловлен стремлением учесть краткосрочную инерционность процесса, характерную для большинства сенсорных данных, а также избежать излишнего усложнения модели за счёт большого числа признаков.

Для формирования лагов использовалась библиотека `pandas`: к столбцу `value` последовательно применялся метод `shift()` с соответствующими сдвигами. Поскольку при сдвиге для первых нескольких наблюдений возникают пропущенные значения (`NaN`), они были удалены с помощью `dropna()`, чтобы не нарушать работу алгоритмов машинного обучения. В результате итоговый датафрейм содержит для каждой временной точки три признака-предиктора и целевую переменную `value`. Пропуски и дубликаты в подготовленных данных отсутствуют.

Разделение данных на обучающую и тестовую выборки не производилось на данном этапе — оно будет выполнено позже с сохранением временного порядка для корректной оценки качества прогнозирования. Подготовленная матрица признаков готова для подачи в модели (линейную регрессию, случайный лес, LSTM и т.д.). Важно отметить, что дополнительные признаки, такие как скользящее среднее или стандартное отклонение, в данной работе не использовались, чтобы сосредоточиться на оценке базовой прогностической способности лаговой структуры.

Таблица 1 – Пример формирования лаговых признаков

Время	value	lag1	lag2	lag3
2014-04-01 00:15:00	21.490266	19.961641	20.500833	19.761252
2014-04-01 00:20:00	20.187739	21.490266	19.961641	20.500833
2014-04-01 00:25:00	19.923126	20.187739	21.490266	19.961641
2014-04-01 00:30:00	21.698404	19.923126	20.187739	21.490266
2014-04-01 00:35:00	20.878758	21.698404	19.923126	20.187739

Создание лаговых признаков позволило преобразовать задачу прогнозирования временного ряда в стандартную задачу обучения с учителем, сохранив при этом временную зависимость между наблюдениями. Полученный набор признаков (три лага) далее использовался для обучения моделей, а качество прогнозов оценивалось на отложенной тестовой выборке.

3.2 Базовая модель прогнозирования

В качестве базовой модели прогнозирования была выбрана **линейная регрессия** из библиотеки `scikit-learn`. Данный выбор обусловлен несколькими факторами. **Во-первых**, линейная регрессия является простейшей и наиболее интерпретируемой моделью машинного обучения, что делает её идеальным базовым алгоритмом для сравнения с более сложными методами (LSTM). **Во-вторых**, несмотря на свою простоту, линейная регрессия часто демонстрирует приемлемые результаты на временных рядах с выраженной линейной зависимостью между текущими и лаговыми значениями. **В-третьих**, модель обладает высокой вычислительной эффективностью, что особенно важно при необходимости быстрого обучения и прогнозирования в потоковых системах.

Подготовка данных для обучения включала формирование матрицы признаков из трёх лагов (`lag1`, `lag2`, `lag3`) и целевой переменной `value`. Разделение данных на обучающую и тестовую выборки было выполнено в пропорции **70/30** с сохранением временного порядка наблюдений: первые 70% точек составили обучающую выборку (`X_train`, `y_train`), оставшиеся 30% — тестовую (`X_test`, `y_test`). Сохранение хронологической последовательности критически важно для корректной оценки прогностической способности модели, поскольку использование данных из будущего при обучении привело бы к нереалистично завышенным оценкам качества.

Модель линейной регрессии обучалась на подготовленных данных без дополнительной настройки гиперпараметров, поскольку в данном случае регуляризация не применялась, а коэффициенты регрессии вычисляются аналитически методом наименьших квадратов. Процесс обучения включал минимизацию суммы квадратов ошибок между фактическими значениями и предсказаниями модели. После обучения модель была применена к тестовой выборке, получены прогнозы `pred` для теста и `pred_2` для обучения (для внутреннего контроля качества).

Для оценки качества прогнозирования использовались две метрики: средняя абсолютная ошибка (MAE) и корень из среднеквадратичной ошибки (RMSE). MAE позволяет оценить среднее абсолютное отклонение прогноза от фактического значения и является легко интерпретируемой метрикой. RMSE более чувствительна к крупным ошибкам прогнозирования, что особенно

важно при обнаружении аномалий, так как большие отклонения могут свидетельствовать о нештатных ситуациях.

Результаты обучения модели линейной регрессии показали, что базовый алгоритм способен прогнозировать значения временного ряда с приемлемой точностью:

- $MAE = 3.362$ — средняя абсолютная ошибка прогноза составляет около 3.4 единиц, что в сравнении со средним значением ряда (44.49) даёт относительную ошибку около 7.6%.
- $RMSE = 7.33$ — среднеквадратичная ошибка указывает на то, что крупные отклонения прогнозов от фактических значений в среднем составляют 7.33 единицы.

Визуальное сравнение фактических и прогнозных значений показывает, что линейная регрессия удовлетворительно воспроизводит общую динамику ряда на тестовом участке, однако на участках резких пиковых значений ошибка прогнозирования заметно возрастает. Это ожидаемо, поскольку линейная модель не способна улавливать сложные нелинейные зависимости и резкие изменения, характерные для аномальных событий. Именно эта особенность — рост ошибки на аномалиях — делает линейную регрессию полезным инструментом для последующего обнаружения выбросов: точки с высокими ошибками прогноза могут рассматриваться как потенциальные аномалии.




Рис. 3. Прогноз линейной регрессии

Полученные результаты будут использованы в качестве **базового порога** для сравнения с более сложной моделью LSTM. Улучшение метрик на LSTM относительно линейной регрессии позволит оценить преимущества нейросетевого подхода при работе с нелинейными паттернами временных рядов.

```

from sklearn.model_selection import train_test_split

X = model_df[['lag1', 'lag2', 'lag3']]
y = model_df['value']

split = int(len(model_df)*0.7)

X_train = X[:split]
X_test = X[split:]

y_train = y[:split]
y_test = y[split:]

from sklearn.linear_model import LinearRegression

model = LinearRegression()
model.fit(X_train, y_train)
pred = model.predict(X_test)
pred_2 = model.predict(X_train)
from sklearn.metrics import mean_absolute_error
from sklearn.metrics import mean_squared_error
import numpy as np

mae_1 = mean_absolute_error(y_test, pred)
rmse_1 = np.sqrt(mean_squared_error(y_test, pred))

print("MAE =", round(mae_1,3))
print("RMSE =", round(rmse_1,3))

MAE = 3.362
RMSE = 7.33

```

Рис. 4. Код обучения линейной регрессии

3.3 Дополнительная модель прогнозирования

В качестве дополнительной, более сложной модели прогнозирования была выбрана **рекуррентная нейронная сеть с долгой краткосрочной памятью (LSTM)**. Данный выбор обусловлен способностью LSTM эффективно улавливать долговременные зависимости в последовательных данных, что особенно важно для временных рядов с нелинейной динамикой и сложными паттернами. В отличие от линейной регрессии, LSTM может моделировать нелинейные взаимосвязи между наблюдениями, разделёнными во времени, благодаря наличию внутренних состояний (ячеек памяти) и механизмов «ворот», управляющих потоком информации [1]. Это делает её потенциально более мощным инструментом для прогнозирования телеметрических данных.

Подготовка данных включала несколько этапов. Исходный ряд значений был преобразован в одномерный массив и разделён на обучающую (70%) и

тестовую (30%) выборки с сохранением временного порядка. Поскольку LSTM чувствительна к масштабу входных данных, значения были **нормализованы** в диапазон $[0, 1]$ с помощью `MinMaxScaler`. Масштабирование выполнялось отдельно на обучающей выборке, после чего тестовые данные преобразовывались с использованием тех же параметров, чтобы избежать утечки информации.

Для обучения с учителем были сформированы **последовательности** длины `look_back = 3` (соответствует трём предыдущим наблюдениям). Функция `create_dataset` создаёт пары «вход – выход», где вход — это три последних значения, а выход — следующее значение. Таким образом, сохраняется структура, аналогичная лаговым признакам, но в формате, удобном для LSTM (трёхмерные тензоры: `[samples, timesteps, features]`). Для тестовой выборки последовательности строились с учётом последних трёх точек обучающего набора, чтобы обеспечить непрерывность прогноза.

Архитектура модели состояла из одного слоя LSTM с **64 нейронами** и полносвязного выходного слоя с одним нейроном (для регрессии). В качестве функции потерь использовалась **среднеквадратичная ошибка (MSE)**, оптимизатор — **Adam**. Для предотвращения переобучения применялся **EarlyStopping** с мониторингом валидационной потери, терпением `patience = 10` и восстановлением наилучших весов. Обучение проводилось в течение 50 эпох с размером батча 32 и долей валидации 10% от обучающего набора.

После обучения модель сделала прогнозы на тестовом наборе. Предсказанные значения были **обратно масштабированы** в исходный диапазон с помощью `inverse_transform` для корректного сравнения с фактическими значениями. Оценка качества выполнялась по тем же метрикам, что и для линейной регрессии: **MAE** и **RMSE**.

Результаты модели LSTM оказались следующими:

- **MAE** = 4.028
- **RMSE** = 8.538

Сравнивая с линейной регрессией (**MAE** = 3.362, **RMSE** = 7.33), можно заметить, что LSTM показала **несколько худшие** результаты на данном наборе данных. Это может быть объяснено рядом факторов: относительно небольшой объём выборки (4032 точки) и короткая длина последовательности (всего 3 шага), что не позволяет в полной мере раскрыть потенциал LSTM, требующей большего количества данных для обучения устойчивым внутренним представлениям. Кроме того, сам ряд имеет выраженные пиковые выбросы, которые LSTM, будучи чувствительной к масштабу, не всегда корректно прогнозирует без дополнительной предобработки. Тем не менее, LSTM

остаётся перспективным инструментом для более длинных и зашумлённых рядов, где её способность запоминать долгосрочные зависимости может дать существенное преимущество.

Визуальное сопоставление фактических и прогнозных значений демонстрирует, что LSTM в целом повторяет тренд, однако на резких скачках ошибка возрастает. Это поведение согласуется с теоретическими ожиданиями: нейросетевая модель не всегда превосходит простые линейные методы при малом объёме данных, но может быть полезна как компонент гибридных систем или при увеличении глубины истории.




Рис. 5. Результат работы LSTM




Рис. 6. Детектирование аномалии с помощью IQR




Рис. 7. По ошибке прогноза

```
model = Sequential()

model.add(
    LSTM(
        64,
        input_shape=(look_back,1)
    )
)

model.add(Dense(1))

model.compile(
    optimizer='adam',
    loss='mse'
)

early_stop = EarlyStopping(
    monitor='val_loss',
    patience=10,
    restore_best_weights=True
)

history = model.fit(
    X_train,
    y_train,
    epochs=50,
    batch_size=32,
    validation_split=0.1,
    callbacks=[early_stop],
    verbose=1
)
```

Рис. 8. Код создания и обучения LSTM

Полученные результаты позволяют сделать вывод, что для данного конкретного временного ряда линейная регрессия на лаговых признаках обеспечивает достаточную точность, а LSTM не даёт значимого улучшения. Однако в дальнейшем, при работе с более сложными многомерными данными или с увеличенным горизонтом прогнозирования, LSTM может оказаться предпочтительнее. Кроме того, ошибки прогнозирования обеих моделей могут быть использованы в качестве сигналов для обнаружения аномалий, что будет рассмотрено в следующем разделе.

3.4 Сравнение моделей прогнозирования

Сравнительный анализ моделей прогнозирования проводился по двум ключевым метрикам качества: **средней абсолютной ошибке (MAE)** и **корню из среднеквадратичной ошибки (RMSE)**, вычисленным на тестовой выборке (30% от общего объёма данных). В качестве базовой модели выступала линейная регрессия на трёх лаговых признаках, а в качестве дополнительной — рекуррентная нейронная сеть LSTM с аналогичной архитектурой (последовательность из трёх предыдущих наблюдений). Сравнительная таблица метрик показывает, что **линейная регрессия превосходит LSTM по обоим показателям**.

Метрика	Линейная регрессия	LSTM	Лучшая модель
MAE	3.362	4.028	Линейная регрессия
RMSE	7.33	8.538	Линейная регрессия

Таким образом, по результатам сравнения линейная регрессия демонстрирует более высокую точность прогнозирования на тестовой выборке: улучшение по MAE составляет около **16.5%** (с 4.028 до 3.362), по RMSE — примерно **14.2%** (с 8.538 до 7.33). Преимущество линейной модели в данном случае может быть объяснено несколькими факторами.

Во-первых, исследуемый временной ряд имеет относительно небольшой объём (4032 наблюдения) и короткую историю (всего три лага). Линейная регрессия, будучи параметрической моделью с малым числом параметров, легко обучается на таких данных и даёт стабильные прогнозы. LSTM, напротив, является нелинейной моделью с большим числом обучаемых параметров (включая веса вентиляей и рекуррентные связи), для эффективного обучения которой требуются существенно большие выборки. В условиях ограниченных данных LSTM может как недообучаться (не улавливать

сложные паттерны), так и переобучаться на шуме, что негативно сказывается на обобщающей способности.

Во-вторых, природа временного ряда, по-видимому, достаточно близка к линейной авторегрессионной зависимости: текущее значение хорошо объясняется линейной комбинацией трёх предыдущих отсчётов. Это подтверждается низкой ошибкой линейной модели. LSTM, пытаясь моделировать более сложные нелинейные взаимодействия, не получает значимого выигрыша, поскольку таких взаимодействий в данных либо нет, либо они подавлены шумом.

В-третьих, LSTM чувствительна к масштабу и выбросам. Хотя данные были нормализованы, резкие пиковые значения (максимум 164.95 при медиане 21.65) создают сложности для нейросетевой модели: она может смещать прогнозы в сторону высоких значений, увеличивая ошибку на нормальных участках. Линейная регрессия, в свою очередь, менее подвержена влиянию отдельных выбросов благодаря минимизации суммы квадратов ошибок по всей выборке.

Визуальное сравнение фактических и прогнозных значений подтверждает количественные результаты. Обе модели удовлетворительно воспроизводят общий тренд и основные колебания ряда. Однако прогнозы линейной регрессии более гладкие и стабильные, тогда как LSTM на отдельных участках демонстрирует заметные отклонения, особенно вблизи пиковых значений. На аномальных всплесках ошибка обеих моделей возрастает, что ожидаемо и может быть использовано в дальнейшем для обнаружения выбросов.

Таким образом, для данного конкретного набора данных линейная регрессия оказалась предпочтительнее как по точности, так и по вычислительной простоте. LSTM не дала улучшения, что не снижает её ценности как инструмента для более сложных и длинных временных рядов, где нелинейные эффекты и долгосрочные зависимости играют существенную роль.

Заключение

В ходе выполнения учебной практики был разработан учебный прототип системы прогнозирования и обнаружения аномалий во временных рядах на основе набора данных Numenta Anomaly Benchmark (NAB). Все поставленные задачи были выполнены в полном объёме: выбран и загружен временной ряд (4032 наблюдения с шагом 5 минут), проведён его визуальный анализ, построены две модели прогнозирования (линейная регрессия и LSTM) с использованием лаговых признаков, выполнено обнаружение аномалий статистическим методом межквартильного размаха (IQR).

Сравнительный анализ моделей прогнозирования показал, что линейная регрессия на трёх лаговых признаках демонстрирует более высокую точность, чем LSTM. Линейная регрессия достигла значений **MAE = 3.362** и **RMSE = 7.33**, тогда как LSTM показала **MAE = 4.028** и **RMSE = 8.538**. Улучшение по MAE составляет около 16.5%, по RMSE — 14.2%. Преимущество линейной модели объясняется малым объёмом выборки и близостью динамики ряда к линейной авторегрессионной зависимости, тогда как LSTM, будучи более сложной нелинейной моделью, не получила достаточного объёма данных для эффективного обучения и оказалась чувствительной к пиковым выбросам.

Обнаружение аномалий методом межквартильного размаха (IQR) позволило выявить **12 аномальных точек** в исследуемом ряду. Данные точки находятся за пределами диапазона $[Q_1 - 1.5 \cdot IQR, Q_3 + 1.5 \cdot IQR]$ и соответствуют резким пиковым значениям, что хорошо согласуется с визуальным анализом. Применение данного метода подтвердило его эффективность для выявления выраженных выбросов в одномерных временных рядах. Дополнительное использование z-оценки на данном наборе данных могло бы дать схожие результаты, однако в рамках работы акцент был сделан на более устойчивом к выбросам методе IQR.

Практическая значимость разработанного прототипа заключается в возможности его использования для оперативного мониторинга сенсорных данных в реальном времени: прогнозирование позволяет предвидеть поведение системы, а обнаружение аномалий — своевременно сигнализировать о нештатных ситуациях. Простота и интерпретируемость линейной регрессии делают её удобным базовым инструментом, а статистические методы обнаружения аномалий не требуют размеченных данных и легко внедряются в существующие системы.

Дальнейшее развитие системы может включать увеличение глубины лагов, применение более сложных моделей (например, градиентный бустинг или гибридные архитектуры) при наличии большего объёма данных, а также интеграцию многомерного анализа для учёта корреляций между несколькими датчиками. Кроме того, перспективным направлением является использование ошибок прогнозирования (как для линейной регрессии, так и для LSTM) в качестве дополнительного критерия для обнаружения аномалий.

Разработанный прототип и все материалы практики доступны в репозитории: https://github.com/KokRoch/time_practice

СПИСОК ЛИТЕРАТУРЫ

- [1] Хуснутдинов А. О., Хабаров В. И. Глубокое обучение для анализа многомерных временных рядов: систематизация типов данных,

задач, архитектур и подходов // Системы анализа и обработки данных. – 2025. – Вып. 3(99). – URL: <https://cyberleninka.ru/article/n/glubokoe-obuchenie-dlya-analiza-mnogomernyh-vr> (дата обращения: 28.06.2026).

[2] Шильцина Е. А. Применение машинного обучения для прогнозирования временных рядов // Вестник науки. – 2025. – № 5 (86), Т. 2. – С. 953–960. – URL: <https://cyberleninka.ru/article/n/primenenie-mashinnogo-obucheniya-dlya-prognozirovaniya-vremennyh-ryadov> (дата обращения: 28.06.2026).

[3] Краева Я. А. Обнаружение аномалий временного ряда на основе технологий интеллектуального анализа данных и нейронных сетей // Вестник ЮУрГУ. Сер. Вычислительная математика и информатика. – 2023. – Т. 12, № 3. – URL: <https://cyberleninka.ru/article/n/obnaruzhenie-anomaliy-vremennogo-ryada-na-osnove-tehnologiy-intellektualnogo-analiza-dannyh-i-neyronnyh-setey> (дата обращения: 28.06.2026).

[4] Кечеджиев А. С., Цветкова О. Л. Исследование обнаружения аномалий с использованием Isolation Forest в машинном обучении // Программная инженерия. – 2024. – Т. 15, № 1. – С. 106–112. – DOI: 10.21822/2073-6185-2024-51-1-106-112. – URL: <https://cyberleninka.ru/article/n/issledovanie-obnaruzheniya-anomaliy-s-ispolzovaniem-isolation-forest-v-mashinnom-obuchenii> (дата обращения: 28.06.2026).

[5] Станиславский С. В. Метод обнаружения аномалий во временных рядах // Молодой учёный. – 2024. – № 50 (549). – URL: <https://moluch.ru/archive/549/120519> (дата обращения: 28.06.2026).

[6] Вышкваркова Е. В., Греков А. Н., Маврин А. С. Application of the ARIMA model to anomaly detection in the bivalve activity data // Системы контроля окружающей среды. – 2023. – Вып. 3 (53). – URL: <https://msoe.ru/articles/2023/53-15> (дата обращения: 28.06.2026).

[7] Сухов В. А. Метод поиска аномалий временного ряда в режиме реального времени // Вестник СПбГПУ. Серия «Информатика. Телекоммуникации. Управление». – 2024. – URL: <https://elib.spbstu.ru/dl/3/2024/vr/vr24-5843.pdf> (дата обращения: 28.06.2026).